

Arquitetura RAG: Guia de Implementação

1. O que é RAG (Retrieval-Augmented Generation)?

A arquitetura RAG é uma técnica que combina o poder de geração de texto dos Modelos de Linguagem de Grande Escala (LLMs) com a precisão de sistemas de recuperação de informação. Em vez de confiar apenas no conhecimento interno do modelo (que pode estar desatualizado ou sujeito a alucinações), o RAG permite que o modelo consulte uma base de dados externa antes de formular uma resposta.

Essencialmente, o RAG funciona como um exame de "consulta aberta": o modelo recebe a pergunta, procura nos "livros" (sua base de dados) e utiliza o que encontrou para responder.

2. Passos do Pipeline RAG

Passo 1: Ingestão de Dados

Os documentos (PDFs, Markdown, etc.) são divididos em fragmentos menores (chunks). Cada fragmento é transformado num vetor numérico (embedding) que representa o seu significado semântico.

Passo 2: Armazenamento

Estes vetores são guardados numa Vector Database (como Pinecone, ChromaDB ou Weaviate), permitindo buscas ultra-rápidas por similaridade.

Passo 3: Recuperação (Retrieval)

Quando o utilizador faz uma pergunta, esta também é convertida num vetor. O sistema procura na base de dados os fragmentos de texto mais semelhantes à intenção da pergunta.

Passo 4: Aumento e Geração (Augmented Generation)

Os fragmentos recuperados são inseridos no "prompt" enviado ao LLM como contexto. O modelo lê o contexto e gera a resposta final baseada nesses factos.

3. Melhores Práticas

Estratégia de Chunking

Não use tamanhos de fragmentos aleatórios. Tente manter o contexto semântico (ex: 512 tokens com 10-20% de sobreposição/overlap) para evitar que uma frase importante seja cortada ao meio.

Metadados e Filtragem

Adicione metadados (data, autor, categoria) aos seus fragmentos. Isso permite filtrar a busca antes mesmo de aplicar a similaridade vetorial, aumentando a precisão.

Re-ranking

A busca vetorial pode trazer resultados próximos mas não ideais. Use um modelo de "Re-ranker" para reordenar os top 5 ou 10 resultados, garantindo que o conteúdo mais relevante esteja no topo para o LLM.

4. Testes de Validação

Para verificar se o modelo está a utilizar o contexto corretamente e não a "inventar", utilize as seguintes perguntas de teste:

Objetivo do Teste	Pergunta Sugerida
Verificar Alucinação	"Com base apenas nos documentos fornecidos, o que é dito sobre [tema que não existe na base]?"
Extração de Factos	"Quais são os três principais pontos mencionados no documento [Nome do Doc]?"
Síntese de Contexto	"Como é que a informação do Documento A se relaciona com a conclusão do Documento B?"
Prioridade de Contexto	Pergunte algo onde o senso comum diz 'Sim', mas o seu documento diz 'Não'.